

SDKB v1.0

반도체 도메인 온톨로지 큐레이션 구축 실행계획

기술경영 관점의 공개 데이터셋 설계 및 연구 논문 통합 버전

성균관대학교 기술경영전문대학원 박사과정

박형식 (Park HyungSik) | 학번: 2025730080

지도교수: 신준석 교수 (Technology Foresight)

현업프로젝트1 | 2026년 4월 ~ 6월 (12주)

Version 2.0 | 2026-04-12

목 차

Executive Summary.....	4
1. 연구 배경 및 목표.....	5
1.1 문제 배경.....	5
1.2 핵심 문제 정의.....	5
1.3 본 학기(2026-1) 프로젝트 목표.....	5
1.4 후속 학기 계획(사업화 로드맵).....	6
2. 기술예측(Technology Foresight) 관점의 온톨로지 설계 프레임워크.....	7
2.1 기술예측과 온톨로지의 연계.....	7
2.2 STEEPVE 프레임워크 연계 설계.....	7
2.3 기술경영 의사결정 지원 시나리오.....	7
3. Baseline semiconductor_v0_3 구조 분석.....	9
3.1 메타데이터 및 구성요소.....	9
3.2 14개 노드 타입(클래스) 현황.....	9
4. SDKB v1.0 목표 아키텍처.....	10
4.1 레이어링 원칙: Domain / Governance / Link-Only.....	10
4.2 다중 스케일 온톨로지 융합 아키텍처.....	10
4.3 SEMI 표준 내재화 (E10/E30/E40/E116/EDA).....	10
4.3.1 장비 상태 모델 (SEMI E10).....	10
4.3.2 통신 프로토콜 및 처리 관리 (E30/E40/EDA).....	11
5. FBSFM 기반 FMEA 인과관계 추론 고도화.....	12
5.1 FBSFM 모델과 반도체 도메인 매핑.....	12
5.2 관계 타입 확장 및 신뢰도·증거 표현.....	12
6. 지정학적 리스크 및 규제 지식 코드화.....	13
6.1 BIS 수출통제 (EAR/Entity List/\$744.23).....	13
6.2 NIST CSF 2.0 / IR 8546 (보안·공급망 거버넌스).....	13
6.3 ECHA SCIP (소재-규제 리스크).....	13
7. Ontology Alignment 전략과 소스별 정합 절차.....	14
7.1 매핑 알고리즘 (lexical + embedding hybrid).....	14
7.2 소스별 정합 절차 요약.....	14
7.3 불일치 해결 정책.....	14
8. Provenance-JSON-LD-SHACL 검증 체계.....	15
8.1 PROV-O 기반 출처·라이선스 모델.....	15
8.2 JSON-LD 매핑 규칙.....	15
8.3 SHACL 기반 검증·QA.....	15
8.4 FAIR 데이터 원칙 준수.....	15
9. 합성 데이터셋 구축 및 평가 체계 (현업프로젝트 연계).....	16
9.1 전문가 프로필 데이터셋 (100명 규모).....	16
9.2 기술 문제 세트 (50개) 및 규제 시나리오 (25개).....	16

9.3 정답(Ground Truth) 평가 체계	16
10. 12주 실행 파이프라인 (2026.04 ~ 2026.06)	17
10.1 4단계 큐레이션 파이프라인	17
10.2 주차별 세부 실행계획	17
11. 릴리스 패키지 및 배포 전략	19
11.1 배포 번들 구성	19
11.2 데이터셋 카드 구성 지침	19
11.3 공개 라이선스 전략	19
12. 평가 지표 및 SPARQL 예시 쿼리	21
12.1 평가 지표	21
12.2 대표 SPARQL 예시 쿼리 3개	21
13. 위험·제약 및 완화책	22
14. 기대 성과	23
14.1 경제적 기대효과	23
14.2 정성적 기대효과	23
14.3 연구 논문 기여 포지셔닝	23
15. 분석방법론 학습 계획	24
참고 자료	25

Executive Summary

본 문서는 반도체 도메인 지식 베이스(SDKB: Semiconductor Domain Knowledge Base) v1.0을 12주 이내에 "공개 가능한 Open Core"와 "유료/제한 소스 Link-Only"를 명확히 분리하여 구축하는 최적 실행계획을 제시합니다. 특히 본 버전은 다음 세 가지 문서의 요구사항을 통합하여 보완하였습니다:

① **현업프로젝트1 계획서**: SDKB 온톨로지 설계(198+ 노드/264+ 간선), 합성 데이터셋 구축(전문가 프로필 100명, 기술문제 50개, 규제 시나리오 25개), 정답 평가체계(3인 교차평가, 7,500개 평점), 기술 사업화 전략 초안

② **박사과정 예비신청원 [1순위]**: 기술예측(Technology Foresight) 관점의 온톨로지 설계 프레임워크, STEEPVE 프레임워크 연계, 기술 포트폴리오 분석/격차 식별/공급망 리스크 예측 등 기술경영 의사결정 지원, 3개월 압축 일정(2026.04~06), FAIR 데이터 원칙

③ **최적 방안 제안서**: 다중 스케일 온톨로지 융합 아키텍처(SemiKong+SemicONTO), SEMI 표준 내재화(E10 6대 장비상태/E30/E40/E116/EDA), FBSFM 기반 인과추론 고도화, BIS TPP 임계값 정량화, NIST CSF 2.0 OT 보안 연계, ECHA SCIP SVHC 추적, 4단계 큐레이션 파이프라인, 데이터셋 카드 상세 지침

핵심 설계 원칙은 (1) OWL+JSON-LD 이중 스키마 고도화, (2)

SemiKong·SemicONTO·SEMI·NIST·BIS·ECHA와의 자동+전문가 혼합 정합, (3) PROV-O 기반 프로비넌스와 SHACL 기반 품질검증을 릴리스 게이트로 고정하는 것입니다.

1. 연구 배경 및 목표

1.1 문제 배경

반도체 제조 산업에서 숙련 엔지니어의 은퇴가 가속화되면서 수십 년간 축적된 공정 노하우(암묵지)의 단절 위기가 심화되고 있습니다. 특히 소재·부품·장비(소부장) 중소·중견기업(SME)은 공정 결함 해결, 장비 최적화 등 고도의 전문 기술이 필요하나 적합한 전문인력을 찾을 역량이 부족하여 정보 비대칭이 구조적으로 존재합니다.

동시에, 범용 AI나 대규모 언어 모델(LLM)은 반도체 도메인의 복잡한 물리·화학적 상호작용, 나노미터 단위의 공정 변수, 그리고 산업 표준 및 규제의 의미론적 맥락을 정확히 추론하는 데 근본적 한계를 보이고 있습니다. 미국 수출관리규정(EAR), 한국 산업기술보호법 등 다중 관할 수출통제가 강화되면서 전문가-의뢰인 매칭 시 규제 적합성 검증이 필수적이거나, 기존 매칭 서비스는 이를 체계적으로 지원하지 못하고 있습니다.

1.2 핵심 문제 정의

- (1) 전문인력 매칭 알고리즘 개발·검증을 위한 표준화된 데이터셋의 부재: 반도체 소부장 도메인에 특화된 전문가 프로필, 기술 문제 정의, 규제 시나리오를 포함하는 벤치마크 데이터셋이 존재하지 않음
- (2) 규제 준수를 아키텍처 수준에서 보장하는 매칭 시스템의 부재: 기존 추천 시스템은 규정 준수를 사후 필터로만 처리하여 구조적 누수(leakage)를 허용
- (3) 기술경영 관점의 기술예측(Foresight) 프레임워크와 연계된 도메인 지식그래프의 부재: 공정 기술 간 계층 관계와 인과 구조를 온톨로지로 정형화하여 기술 포트폴리오 분석, 격차 식별, 공급망 리스크 예측을 체계적으로 지원하는 공개 데이터셋이 부재

1.3 본 학기(2026-1) 프로젝트 목표

본 학기에는 전체 사업화 로드맵의 1단계로서, 다음 5개 목표를 달성합니다:

- ① 반도체 도메인 온톨로지(SDKB) 설계: 공정·장비·결함·스킬 엔터티 및 관계 구조를 정의하고, 198개 이상 노드와 264개 이상 간선을 포함하는 지식그래프를 구축, 기술예측(Foresight) 관점의 설계 프레임워크 수립

- ② 전문가 프로필 데이터셋(100명 규모) 생성: 기술 역량, 경력, 관할 정보를 포함하는 비식별화된 합성 프로필을 도메인 전문가 자문을 통해 현실성 있게 구성
- ③ 기술 문제 세트(50개) 및 규제 시나리오(25개 적대적 사례 포함) 작성: 소부장 SME가 실제 직면하는 공정 결함, 소재 이슈 등을 체계적으로 정의하고, 다중 관할 수출통제 경계 조건을 테스트하는 시나리오 설계
- ④ 정답(ground truth) 평가 체계 구축: 도메인 전문가 3인에 의한 교차 평가를 통해 7,500개 정답 평점을 확보하고, 평가자 간 신뢰도(weighted kappa, ICC)를 검증
- ⑤ 기술사업화 전략 초안 수립: 시장 규모 추정, 목표 고객 정의, 수익 모델 초안, 경쟁 분석을 포함하는 기술사업화 전략서 작성

1.4 후속 학기 계획(사업화 로드맵)

2단계(2026-2학기): 검증된 데이터셋 기반 AFCEP-EM(에이전트 우선 컴플라이언스 플랫폼) 매칭 알고리즘 구현 및 성능 평가(MRR, NDCG@5, 누수율 등)

3단계(2027-1학기): 프로토타입 플랫폼 개발 및 파일럿 운영, 기술사업화 최종 전략 확정 및 창업 실행

2. 기술예측(Technology Foresight) 관점의 온톨로지 설계 프레임워크

2.1 기술예측과 온톨로지의 연계

본 연구는 기술경영학의 기술예측(Technology Foresight) 관점을 최우선으로 견지합니다. 공정 기술 간의 계층적 관계와 고장 인과 구조를 기계가 판독 가능한 형태(JSON-LD, OWL)로 정형화함으로써, 단순한 백과사전식 지식 검색을 넘어 고도화된 의사결정을 체계적으로 지원하는 포괄적 분석 프레임워크의 청사진을 제시합니다.

2.2 STEEPVE 프레임워크 연계 설계

STEPPVE는 사회(Social), 기술(Technological), 경제(Economic), 환경(Environmental), 정치(Political), 가치(Values), 윤리(Ethical)적 요인을 입체적으로 분석하는 도구입니다. SDKB v1.0에서는 이러한 거시적 환경 요인을 온톨로지 관계 가중치(Weight)로 환산하여 시나리오 분석을 지원합니다.

STEPPVE 차원	반도체 도메인 매핑 및 시나리오 추론 변수
사회 (Social)	첨단 팩 운영을 위한 고급 공학 인력의 공급 부족, 지정학적 인재 유출
기술 (Technological)	3nm 이하 초미세 공정 진입, 하이브리드 본딩, 실리콘 포토닉스 등 차세대 패키징 기술
경제 (Economic)	EV 등 전방 산업 수요 부진에 따른 레거시 반도체 공급 과잉 및 가격 하락
환경 (Environmental)	ESG 규제 강화 및 탄소중립 달성을 위한 팩 내 재생 에너지 사용 압박 (SCIP 연계)
정치 (Political)	미-중 패권 경쟁에 따른 희토류, 핵심 화합물 수출 통제 및 공급망 블록화 (BIS 연계)
가치/윤리 (Values/Ethical)	분쟁 광물 사용 금지, 책임 있는 AI 반도체 공급망 생태계 요구

2.3 기술경영 의사결정 지원 시나리오

- ① 기술 포트폴리오 최적화: 기업의 내부 R&D 역량(특히, 적용 공정 기술)과 시장 수요 변화를 비교 분석하여 기술 격차(Gap) 식별
- ② 공급망 리스크 선제적 식별: 지정학적 요인으로 핵심 식각 가스의 수급이 제한될 경우, 경제적 손실 규모와 대체 기술 공정 적용 시 재설계 기간을 GraphRAG 시스템으로 시뮬레이션
- ③ 전문가 검색 및 매칭: 한/영 동의어 포함 EUV 레지스트 검색 → 관련

SubProcess/Material/FailureMode 연결 탐색

④ 결함 진단: 특정 공정에서 관측된 불량률의 원인/완화 경로 추출

⑤ 규제 리스크 질의: 특정 장비 클래스 입력 → BIS 규칙(\$744.23) 적용 가능성과 Entity List 연계 리스크 반환

3. Baseline semiconductor_v0_3 구조 분석

3.1 메타데이터 및 구성요소

semiconductor_v0_3.json은 상위 메타데이터(version_id, version, status, created_by, notes)와 그래프 본문(nodes 198개, edges 264개), 보조 테이블(synonyms 86개, cases 3개), 출처 레지스트리 (provenance_sources), 품질 통계(provenance_statistics: 검증 필요 노드 71개, 엣지 117개)로 구성됩니다.

3.2 14 개 노드 타입(클래스) 현황

베이스라인은 이미 14개 타입을 사용하고 있어 계획과 구조적으로 일치합니다. SDKB v1.0 설계에서 현재 14개 타입을 Core 타입으로 고정하고, 규제/표준/출처를 위한 추가 타입은 Governance 레이어에서만 확장하는 방식이 안정적입니다.

노드 타입	개수	특징	검증 필요 플래그
Process	8	공정 대분류	0
SubProcess	12	공정 세부 단계	4
EquipmentClass	11	장비 클래스	0
Equipment	42	장비 인스턴스(모델/벤더)	15
Vendor	15	공급업체	0
Organization	2	조직(컨소시엄/기관)	0
Parameter	5	공정 파라미터	0
Metrology	3	계측/검사 방법	0
Material	20	소재 카테고리	0
TechnologyNode	3	기술노드(7nm 등)	0
FailureMode	25	불량/고장 모드	0
RootCause	20	원인	20
Mitigation	20	완화/대응	20
Skill	12	필요 역량	12

4. SDKB v1.0 목표 아키텍처

4.1 레이어링 원칙: Domain / Governance / Link-Only

Domain(Open Core): 공정·장비·소재·파라미터·계측·기술노드·FMEA(불량/원인/완화/스킬) 등 반도체 기술경영 의사결정에 직접 필요한 사실/개념 그래프

Governance(Open Core): 규제/보안/컴플라이언스(NIST CSF 2.0·IR 8546, BIS EAR, ECHA SCIP) 지식을 규칙/임계값/적용 범위로 정형화

Link-Only: 유료/제한/재배포 불명확 소스(SEMI 표준 PDF, JEDEC, IRDS)는 문서 링크/식별자/절 메타데이터만 보유

4.2 다중 스케일 온톨로지 융합 아키텍처

SemiKong의 거시적 공급망 계층(L1 10개 → L2 40개 → L3 162개)을 그대로 삼고, SemicONTO의 미시적 재료과학 의미론을 이중 앵커링 기법으로 직조하는 다중 스케일 매핑을 적용합니다.

융합 레이어	SemiKong	SemicONTO	기술경영 파급효과
소재 구조 모델링	08-materials (가스, 케미컬, 웨이퍼)	Intrinsic/Extrinsic, Acceptor/Donor 조성	원자재 레벨의 화학적 특성 변동이 양산 공정 수율에 미치는 거시적 영향 추론
공정 실험 정합	07-wfe (식각, 증착, 계측 장비)	Experiment, ExperimentalStep, Activity	R&D 시뮬레이션과 양산 라인 간 시맨틱 불일치 해소를 통한 램프업 기간 단축
출처 추적 통합	00-shared (데이터 모델, 산업 표준)	PROV-O: prov:Entity, prov:Agent	실험실과 양산 데이터 주체 간 완벽한 감사(Audit) 추적

4.3 SEMI 표준 내재화 (E10/E30/E40/E116/EDA)

4.3.1 장비 상태 모델 (SEMI E10)

SEMI E10은 장비의 6가지 상호배타적 상태(생산, 대기, 엔지니어링, 예정 가동중단, 예기치 않은 가동중단, 비계획)를 정의합니다. SDKB v1.0에서는 Equipment_State 클래스를 신설하고, E10의 6대 기본 상태를 하위 노드로 구성한 뒤, PROV-O의 prov:Activity와 결합하여 상태 전이의 시간적 연속성과 전후 공정 지연 간 상관관계를 분석할 수 있는 논리적 기반을 마련합니다.

4.3.2 통신 프로토콜 및 처리 관리 (E30/E40/EDA)

SECS/GEM(E30), 처리 관리(E40), EDA(Interface A) 표준을 장비 노드에 hasCommunicationProtocol, supportsInterfaceA, hasJobManagementRule 등의 명시적 속성으로 부여하여 이기종 장비 간 통합 과정의 데이터 누락이나 레시피 오작동의 근본 원인을 식별할 수 있게 합니다. 단, 표준 본문은 Link-Only로 처리하고 식별자/개정본/URL 수준으로만 포함합니다.

5. FBSFM 기반 FMEA 인과관계 추론 고도화

5.1 FBSFM 모델과 반도체 도메인 매핑

FBSFM(Function-Behavior-Structure-Failure Mode) 모델은 시스템 설계 지식과 FMEA를 온톨로지로 통합하는 프레임워크로, 실패모드-원인-영향의 다층 연결을 강조합니다.

FBSFM 계층	반도체 도메인 매핑 시나리오
Function (기능)	플라즈마 식각 공정에서의 정밀한 선택비 유지 및 식각 프로파일 형성
Intended Behavior	반응 챔버 내 온도 균일성 유지 및 부식성 가스 유량의 정밀 제어
Structure (구조)	가스 분사 시스템(Showerhead), 플라즈마 발생기, 온도 감지 센서 네트워크
Unintended Behavior	플라즈마 밀도 국부적 불균일, 폴리머 부산물 과다 축적 (E10 Unscheduled Downtime 유발)
Cause/Effect	원인: 온도 센서 열화로 데이터 노이즈 → 결과: 임계치수(CD) 불량, 수율 급락

5.2 관계 타입 확장 및 신뢰도·증거 표현

기존 관계 타입(OBSERVED_IN, CAUSED_BY, MITIGATED_BY, REQUIRES_SKILL)을 유지하면서 다음을 추가합니다: affectsMetric(FailureMode → Metric), sdkb:confidence(0~1, 전문가/문헌 근거 기반 점수), sdkb:evidence(출처, 서지, URL, snippet_hash, reviewer, review_date 리스트), sdkb:probability(조건부 확률, 데이터가 있을 때만). 베이스라인의 weight는 confidence로 의미를 고정하고, 제약 (constraint)은 sdkb:hardConstraint/sdkb:softConstraint로 명시적으로 분리합니다.

6. 지정학적 리스크 및 규제 지식 코드화

6.1 BIS 수출통제 (EAR/Entity List/\$744.23)

BIS Entity List(Part 744 Supplement No.4)에 포함된 거래 당사자에 대해 추가 라이선스 요구가 발생하며, \$744.23은 반도체 제조장비(SME) 및 advanced-node ICs 관련 end-use 통제를 규정합니다. 특히 총처리능력(TPP) 4800 이상인 칩은 원칙적으로 수출이 엄격히 통제됩니다.

구현: gov:EARRule 노드(\$744.16, \$744.23 등), gov:RegulatedItem 노드(ECCN 코드, 예: 3B001), EquipmentClass에 gov:hasECCN 연결, gov:applicability에 국가군/목적지/최종사용 조건 구조화. SHACL을 활용하여 "TPP 값이 4800 이상일 경우 해당 노드는 자동으로 Export_Restricted 속성을 획득한다"라는 논리적 규칙을 코드화합니다.

6.2 NIST CSF 2.0 / IR 8546 (보안·공급망 거버넌스)

NIST CSF 2.0의 6대 기능(Govern/Identify/Protect/Detect/Respond/Recover)을 gov:NISTFunction으로 노드화하고, IR 8546의 반도체 제조 프로파일 항목을 gov:Outcome으로 만들어 연결합니다. 장비 노드에 NIST 기준의 자산 심각도(Criticality Level: Critical/High 등)를 융합하여, 랜섬웨어 등에 의해 침해될 경우 공정 수율에 미치는 영향을 인과적으로 산출합니다.

6.3 ECHA SCIP (소재-규제 리스크)

EU 시장 공급 제품 중 Candidate List의 SVHC가 0.1% w/w 초과 포함된 경우 2021-01-05부터 ECHA 제출 의무가 있습니다. gov:SCIPReportingRule 노드(임계값 0.1% w/w, 적용일 2021-01-05), Material에 gov:hasSVHC 및 gov:svhcConcentration 속성을 부여하고, SPARQL로 소재→제품구성→SCIP 의무 경로를 추출합니다.

7. Ontology Alignment 전략과 소스별 정합 절차

7.1 매핑 알고리즘 (lexical + embedding hybrid)

후보 생성(자동) → 필터링(규칙/논리) → 전문가 확정(인간)의 3단계: (1) Lexical 매칭:

canonical_name + synonyms 기반 토큰 정규화/약어 확장/편집거리, (2) Embedding 매칭: 라벨+정의 문을 문장 임베딩으로 코사인 유사도 top-k, (3) 제약기반 필터링: 타입 호환 매트릭스, 계층 일관성, 논리적 불일치 검출(LogMap). 대규모 매칭에는 AgreementMakerLight(AML)을 병행 적용합니다.

7.2 소스별 정합 절차 요약

SemiKong: Process Group → Process, Module → SubProcess 상위, Unit → SubProcess 하위. 기존 노드 ID 유지, cross_ref로만 추가.

SemicONTO: Material/Equipment/Process 클래스 간 SKOS 매핑 중심. owl:equivalentClass 남용 회피.

SEMI(E10/E30/E40/E116): StandardReference 노드 생성, sdkb:standardRef로 연결. 본문 반입 금지.

MatKG: CC-BY-4.0 대규모 RDF/CSV, 소재 관련 엔터티/관계 확장에 활용.

Wikidata: CC0 구조화 데이터, 외부 ID 정규화(owl:sameAs) 용도.

7.3 불일치 해결 정책

keep-source(기본값): 두 개념 유지, skos:closeMatch/exactMatch로 연결. merge(강한 증거): 대표 노드로 병합, 원 ID는 sdkb:deprecatedId로 보존. annotate(충돌 미해결): sdkb:conflictNote, sdkb:reviewStatus="DISPUTED"로 표시.

8. Provenance-JSON-LD-SHACL 검증 체계

8.1 PROV-O 기반 출처·라이선스 모델

권장 필드(노드/엣지 공통): prov:wasGeneratedBy → prov:Activity, prov:wasDerivedFrom → 원천 문서/데이터셋, prov:wasAttributedTo → 에이전트, dcterms:license → SPDX 식별자, sdkb:interpretationType → {verbatim|mapped|author-defined}, sdkb:validationRequired → boolean, sdkb:changeSet → 변경이력/릴리스 버전 태깅.

8.2 JSON-LD 매핑 규칙

JSON-LD 1.1 W3C 권고 표준에 따라 RDF/OWL(TTL)과 JSON-LD를 동일 의미(IRI)로 제공합니다.

@context에 sdkb/prov/dcterms 네임스페이스를 선언하고, type="@type", id="@id"로 매핑합니다.

8.3 SHACL 기반 검증·QA

SDKB v1.0은 릴리스 전 SHACL 검증 통과를 필수 게이트로 설정합니다. 유닛 테스트(스키마): ID 유일성, src/dst 참조 존재, 필수 필드 존재. 통합 테스트(SPARQL): 핵심 질의 10개 결과 스냅샷 비교(회귀 테스트). 전문가 검토 워크플로우: validation_required=True 전체(우선), 중심성/빈도 기반 상위 10% 노드, 규제/표준 연결 엣지 100% 샘플링.

8.4 FAIR 데이터 원칙 준수

Findable: DOI/ORCID 등 공신력 있는 외부 식별자 연동, HuggingFace 태그 시스템. Accessible: 공개 저장소에서 표준 프로토콜로 접근. Interoperable: OWL/RDF/JSON-LD/SPARQL 표준 포맷. Reusable: CDLA-Permissive-2.0 라이선스, PROV-O 출처 추적, 데이터셋 카드.

9. 합성 데이터셋 구축 및 평가 체계 (현업프로젝트 연계)

9.1 전문가 프로필 데이터셋 (100 명 규모)

SDKB v1.0의 온톨로지를 기반으로, 기술 역량(공정·장비·소재 전문성), 경력(근무 이력, 프로젝트 경험), 관할 정보(국적, 수출통제 관련 이력)를 포함하는 비식별화된 합성 프로필 100개를 생성합니다. 도메인 전문가(김범수 등) 자문을 통해 현실성을 검증합니다.

9.2 기술 문제 세트 (50 개) 및 규제 시나리오 (25 개)

소부장 SME가 실제 직면하는 공정 결함, 소재 이슈, 장비 최적화 문제를 50개 체계적으로 정의하고, 다중 관할 수출통제 경계 조건을 테스트하는 25개 적대적 사례를 설계합니다. 이는 AFCP-EM 플랫폼의 규제 누수율 0% 목표와 정책 완전성 100% 목표를 검증하기 위한 테스트베드로 활용됩니다.

9.3 정답(Ground Truth) 평가 체계

도메인 전문가 3인에 의한 교차 평가: 100명 전문가 × 50개 문제 × 평가자 3인 × (적합성 1~5점 + 규제 적합 여부) = 총 7,500개 평점 확보. 평가자 간 신뢰도는 weighted kappa 및 ICC(Intraclass Correlation Coefficient)로 검증합니다. 이 데이터셋은 2단계(2026-2학기) AFCP-EM 매칭 알고리즘 성능 평가(MRR, NDCG@5, 누수율)의 기반이 됩니다.

10. 12 주 실행 파이프라인 (2026.04 ~ 2026.06)

10.1 4 단계 큐레이션 파이프라인

1단계 (베이스라인 구조 분석 및 거시적 계층 정합, 4월): semiconductor_v0_3 파싱, 스키마/통계 자동 추출, SemiKong L1~L3 분류 체계 확립, OWL 클래스/속성 설계, ID/네임스페이스 정책 확정, 기술 예측 프레임워크 수립

2단계 (데이터 큐레이션 및 온톨로지 융합, 5월): 14개 노드 타입별 외부 소스 큐레이션, 비정형 텍스트에서 NLP(Lattice-LSTM/PCNN) 기반 자동 추출, 정형 데이터 스프레드시트 기반 대량 매핑, 출처 메타데이터 포함 JSON-LD 스키마 설계, 규제 임계값 코드화, FMEA 기반 인과관계 구축, 합성 데이터셋 생성

3단계 (검증 및 QA, 6월 전반): SHACL shapes 완성, 유닛/통합 테스트, Hermit 추론기 기반 논리적 무결성 검증, 전문가 리뷰(validation_required 중심), 전문가 프로필/문제 세트/규제 시나리오 교차 평가

4단계 (릴리스 및 공개, 6월 후반): SDKB v1.0 완성, HuggingFace 패키징(OWL/TTL, JSON-LD, Parquet, 카드), CDLA-Permissive-2.0 라이선스, 활용 시나리오 문서화, 기술사업화 전략서 초안

10.2 주차별 세부 실행계획

주차	핵심 목표	주요 작업	산출물
1주	베이스라인 완전 파악	v0_3 파싱, 스키마/통계 자동 추출, 결측/중복/참조 무결성 점검	구조리포트, JSON Schema v0.3
2주	메타모델 확정	OWL 클래스/속성 설계, ID/NS 정책, Open Core/Link-Only 분리 규칙, Foresight 프레임워크	sdkb-core.owl 초안, NS/ID 가이드
3주	변환 파이프라인	JSON→RDF(TTL), JSON→JSON-LD, Parquet 추출 스크립트	core.ttl, core.jsonld, nodes/edges.parquet
4주	정합 엔진 v1	lexical+embedding 하이브리드 매핑, 후보 TSV, 리뷰 UI 설계	mappings_candidates.tsv, 리뷰 규칙서
5주	SemiKong 정합	공정 계층 보강, L1→L3 매핑 확정	semikong_alignment.tsv
6주	SemicONTO 정합	OWL 클래스/속성 정합, SKOS 매핑	semicononto_alignment.ttl
7주	SEMI Link-Only + 규제 모델링	E10/E30/E40/E116 참조 그래프, BIS/NIST/ECHA 규칙화	semi_links.ttl, gov/*.ttl

8주	FMEA 고도화 + 합성 데이터	FBSFM 기반 인과 구조 확장, 전문가 프로필 100 명/문제 50개/시나리오 25개 생성	합성 테스트베드
9주	프로비언스 부착	PROV-O 그래프/필드 매핑, license 필드 강제	prov.ttl
10주	검증/QA 게이트	SHACL shapes, 유닛/통합 테스트, 전문가 리뷰	shapes.ttl, 테스트 리포트
11주	전문가 교차평가	3인 교차평가(7,500개 평점), kappa/ICC 검증	평가 결과 데이터셋
12주	릴리스 + 사업화 전략	HF 패키징, 데이터셋 카드, SPARQL 예제, 기술사 업화 전략서	SDKB v1.0 릴리스 번들

11. 릴리스 패키지 및 배포 전략

11.1 배포 번들 구성

파일/폴더	형식	레이어	설명
ontology/sdkb-core.ttl	Turtle	Open Core	핵심 클래스/관계/개념
ontology/sdkb-governance.ttl	Turtle	Open Core	BIS/NIST/ECHA 규칙 노드
ontology/sdkb-links-semi.ttl	Turtle	Link-Only	SEMI 표준 참조
data/nodes.parquet	Parquet	Open Core	노드 테이블
data/edges.parquet	Parquet	Open Core	엣지 테이블
data/expert_profiles.parquet	Parquet	Open Core	전문가 프로필 100명
data/problems.parquet	Parquet	Open Core	기술 문제 50개 + 규제 25개
data/ground_truth.parquet	Parquet	Open Core	교차평가 7,500개 평점
mappings/*.tsv/*.ttl	TSV/TTL	Open Core	SemiKong/SemicONTO 매핑
validation/shapes.ttl	TTL	Open Core	SHACL shapes
provenance/prov.ttl	TTL	Open Core	PROV-O 활동/에이전트/출처
README.md	Markdown	Open Core	Dataset Card
LICENSE.txt	Text	Open Core	CDLA-Permissive-2.0
examples/sparql/	.rq	Open Core	예제 질의 모음

11.2 데이터셋 카드 구성 지침

메타데이터: 태그(semiconductor, ontology, supply-chain, FMEA, foresight), 라이선스(cdla-permissive-2.0), 태스크 카테고리(knowledge-graph). 데이터 구성: SemiKong 기반 L1~L3 노드 수, SemicONTO 매핑 비율, SEMI 표준 범위, FMEA 인과관계 규모, 합성 데이터셋 통계. 큐레이션 프로세스: 학술 문헌, 규제 리스트 버전/업데이트 날짜, 자동화 도구 검증 절차 투명화. 튜토리얼: 모델 학습 환경 설정, GraphRAG 쿼리 스니펫, 파이프라인 샘플 코드. 편향/한계 고지: 공개 문서 및 규제 임계값 기초이므로 개별 팩 기밀 공정 데이터 특수성 미반영 한계 명시.

11.3 공개 라이선스 전략

SDKB v1.0 Open Core 데이터는 CDLA-Permissive-2.0을 기본으로 적용하며, CC-BY-4.0 혼합 출처는 저작자 표시/출처 표기를 유지합니다. Link-Only는 재배포 대상에서 제외하고 식별자/URL/문서명/개

정본 수준으로 제한합니다. CDLA-Permissive-2.0은 데이터셋을 학습하여 파생된 ML 모델 결과물에 대해 원본 라이선스를 승계하도록 강제하지 않아 기업의 법적 불확실성을 제거합니다.

12. 평가 지표 및 SPARQL 예시 쿼리

12.1 평가 지표

정합 품질: 매핑 Precision/Recall/F1(골드셋 기반), 경계 사례 재검토율. FMEA 추론 정확도: SME 판정 정확도, 원인 Top-k hit rate. 품질/재현성: SHACL 통과율(=릴리스 기준), CI 재현 빌드 성공률. 성능: SPARQL 질의 응답시간(p95), 그래프 로딩 시간. 거버넌스 최신성: BIS/NIST/ECHA 규정 업데이트 반영 리드타임(주 단위). 합성 데이터셋: 평가자 간 weighted kappa ≥ 0.6 , ICC ≥ 0.7 .

12.2 대표 SPARQL 예시 쿼리 3 개

① 규제 리스크 질의 (BIS 규칙 + ECCN 연계)

```
SELECT ?equipClass ?eccn ?earRule ?ruleRef WHERE { ?equipClass a sdkb:EquipmentClass ;
sdkb:hasECCN ?eccn . ?eccn a sdkb:RegulatedItem ; sdkb:controlledBy ?earRule . ?earRule a
sdkb:EARRule ; dcterms:bibliographicCitation ?ruleRef . } ORDER BY ?equipClass
```

② FMEA 경로 추출 (불량→원인→완화 + 공정)

```
SELECT ?subprocess ?failureMode ?rootCause ?mitigation ?conf1 ?conf2 WHERE { ?failureMode a
sdkb:FailureMode ; sdkb:occursAtProcessStep ?subprocess ; sdkb:isDueTo ?rootCause ;
sdkb:mitigatedBy ?mitigation . OPTIONAL { ?failureMode sdkb:confidence_isDueTo ?conf1 } OPTIONAL
{ ?failureMode sdkb:confidence_mitigatedBy ?conf2 } } ORDER BY ?subprocess
```

③ 기술 격차 탐지 (기술노드 조건에서 필수 역량/계측 누락)

```
SELECT ?subprocess (COUNT(?skill) AS ?skillCnt) (COUNT(?metro) AS ?metroCnt) WHERE { ?subprocess
a sdkb:SubProcess ; sdkb:relevantForTechNode sdkb:technode/7nm . OPTIONAL { ?subprocess
sdkb:requiresSkill ?skill } OPTIONAL { ?subprocess sdkb:measuredBy ?metro } } GROUP
BY ?subprocess HAVING (COUNT(?skill) = 0 || COUNT(?metro) = 0)
```

13. 위험·제약 및 완화책

리스크/제약	영향	완화책
표준 유료문서 (SEMI/JEDEC/IRDS)	공개 데이터셋 무력화	Link-Only 레이어로 분리, 본문/표 미포함, 식별자/URL만
규제 변경 (BIS/NIST/ECHA)	최신성 저하	규정 노드에 effective_date/retrieved_date 필수화, 월 1회 업데이트
민감 데이터 포함 가능성	법/보안 이슈	security_level(PUBLIC/RESTRICTED) 필드 강제, 리뷰 게이트
FMEA 인과관계 오류	신뢰도 하락	FBSFM 구조화 + evidence/confidence 필수, SME 검토 우선
정합 오류 (동명이의, 계층 불일치)	질의/추론 오류	lexical+embedding + LogMap + AML 혼합 적용
공개 라이선스 혼합 (CC-BY + CDLA)	배포 중단	provenance_sources에 라이선스/저작자 필수, CDLA 호환성 가이드 준수

14. 기대 성과

14.1 경제적 기대효과

반도체 소부장 SME의 전문인력 탐색 비용 연간 약 30% 절감(업체당 연 5,000만원 이상 추정), 매칭 성공률 향상을 통한 기술 문제 해결 기간 단축(평균 3개월→1개월).

14.2 정성적 기대효과

규제 준수 자동화를 통한 수출통제 위반 리스크 원천 차단, 은퇴 전문인력의 지식 재활용 생태계 조성, 학술 논문(IP&M 등 국제저널) 투고 및 기술 창업 기반 확보. 특히 SDKB v1.0은 반도체 AI 연구(전문가 검색, 불량 진단, 공급망 분석, 기술예측 등) 커뮤니티가 다양하게 활용할 수 있는 범용 데이터셋으로 제공됩니다.

14.3 연구 논문 기여 포지셔닝

본 연구의 학술적 기여는 (1) 반도체 도메인 최초의 출처 기반 큐레이션 공개 데이터셋 제공, (2) 기술 예측(Foresight) 관점에서 온톨로지와 기술경영 의사결정을 연계하는 프레임워크 제시, (3) 다중 관할 규제 환경을 온톨로지 수준에서 코드화하는 방법론 제시, (4) 이중 온톨로지 정합의 자동+전문가 혼합 접근법 실증으로 요약됩니다. 목표 저널은 Information Processing & Management(IP&M) 또는 Scientometrics 등 기술경영/정보과학 분야 국제저널입니다.

15. 분석방법론 학습 계획

- ① 기술예측(Foresight) 방법론: 기술 로드맵핑, 시나리오 플래닝, STEEPVE 프레임워크 등 Foresight 기법과 온톨로지 기반 지식 구조화의 연계 방법 학습
- ② 온톨로지 공학: OWL/RDF/SHACL 기반 지식그래프 모델링, 이종 온톨로지 정합(Ontology Alignment) 및 융합 기법
- ③ 데이터 큐레이션 방법론: 출처 추적(Provenance Tracking) 설계, FAIR 데이터 원칙 적용, JSON-LD 스키마 구현
- ④ 기술경영 분석 프레임워크: 기술 포트폴리오 분석, 기술 격차 분석, 공급망 위험 평가 등 의사결정 도구와 데이터셋의 연계 설계

참고 자료

- [1] SemiKong: Curating, Training, and Evaluating A Semiconductor Industry-Specific LLM (arXiv:2411.13802)
- [2] SemicONTO: Initial development of an ontology for the semiconductor domain (CEUR-WS Vol-3760)
- [3] PROV-O: The PROV Ontology (W3C Recommendation, <https://www.w3.org/TR/prov-o/>)
- [4] SHACL: Shapes Constraint Language (W3C Recommendation, <https://www.w3.org/TR/shacl/>)
- [5] JSON-LD 1.1 (W3C Recommendation, <https://www.w3.org/TR/json-ld11/>)
- [6] NIST CSF 2.0 (<https://www.nist.gov/publications/nist-cybersecurity-framework-csf-20>)
- [7] NIST IR 8546: Semiconductor Manufacturing Profile (<https://csrc.nist.gov/pubs/ir/8546/ipd>)
- [8] BIS Entity List (<https://www.bis.gov/entity-list>)
- [9] 15 CFR §744.23: SME and advanced-node ICs end use controls
- [10] ECHA SCIP Database (<https://www.echa.europa.eu/scip>)
- [11] CDLA-Permissive-2.0 (<https://spdx.org/licenses/CDLA-Permissive-2.0.html>)
- [12] FBSFM: An ontological framework for the integration of system design and FMEA (Cambridge, AI EDAM)
- [13] LogMap 2.0: logic-based, scalable ontology matching (Nature Precedings)
- [14] AgreementMakerLight: efficient large-scale ontology matching (Semantic Web Journal)
- [15] MatKG: An autonomously generated knowledge graph in Material Science (Scientific Data)
- [16] KG-Agent: Efficient Autonomous Agent Framework for Complex Reasoning over KG (ACL 2025)
- [17] A Strategic Technology Planning Framework: Taiwan's Semiconductor Foundry Industry
- [18] Hugging Face Dataset Cards (<https://huggingface.co/docs/hub/en/datasets-cards>)
- [19] CDLA Compatibility Guide (<https://cdla.dev/faq-resources/compatibility/>)